
BIG DATA ANALYTICS


WEEK-08 | Supervised Learning - Regression

Yonsei University Jungwon Seo

Classification vs. Regression



이때 Y는 범주형 e.g., (1,0), (True,False), (A, B, C, D)




이때 Y는 숫자형 e.g., 133, 0.11, 103030

기본원리


$$y=3x+1$$

X	у
1	4
2	7
3	10
4	?



Regression

• Error를 최소화 할 수 있는 방정식(Equation)을 찿기



Linear Regression

- 단순 선형회귀
 - y = wx + b
- 다중 선형회귀 (n개의 feature)
 - $y = w_1 x_1 + w_2 x_2 + \dots + w_n x_n + b$
- 가설 (Hypothesis)
 - 변수간의 관계를 유추하기 위해 수학적으로 나타낸 식
 - H(x) = wx + b

Loss function (손실함수)

- 실제값과 예측값과의 차이를 측정 할 수 있는 함수
- Regression Loss Functions

• Mean Squared Logarithmic Error Loss

• Mean Absolute Error Loss => MAE =
$$\frac{\sum_{i=1}^{n} |y_i - x_i|}{n} = \frac{\sum_{i=1}^{n} |e_i|}{n}$$

- Binary Classification Loss Functions
 - Binary Cross-Entropy
 - Hinge Loss
 - Squared Hinge Loss
- Multi-Class Classification Loss Functions
 - Multi-Class Cross-Entropy Loss
 - Sparse Multiclass Cross-Entropy Loss
 - Kullback Leibler Divergence Loss

Optimizer

- Loss function을 이용해서 error 값을 측정을 한다면, 가장 최소의 error를 빠르게 찾는 알고리즘은 없을까?
- Hypotheis 재정의


$$\bullet \ h_{\theta}(x) = \theta_0 + \theta_1 x$$

Cost Function 재정의

•
$$J(\theta_1, \theta_2) = \frac{1}{m} \sum_{i=1}^{m} (h_{\theta}(x^i) - y^i)^2$$


• $J(\theta_1, \theta_2)$ 의 최솟값 찾기


$J(\theta_1,\theta_2)$



Gradient Descent

- 경사하강법
- 함수를 미분해서, 기울기가 음수인 곳을 계속 찾아간다면 언젠간 그 함수의 최솟값에 도달 하지 않을까?





GD Step by Step

• Cost function 정의

$$J(\theta_1, \theta_2) = \frac{1}{m} \sum_{i=1}^{m} (h_{\theta}(x^i) - y^i)^2$$


- 임의의 점에서 시작
 - 예: (0,0),(10,3) 등
- J를 줄이는 θ_1 , θ_2 로 업데이트

$$\theta_j := \theta_j - \alpha \frac{\partial}{\partial \theta_j} J(\theta_0, \theta_1) \quad \text{(for } j = 0 \text{ and } j = 1)$$

 α : learning rate

• 수렴 할 때까지 반복!

Learning Rate



 α 는 작으면 작을 수록 좋을까?

모델의 검증은 어떻게?

<분류문제 - Accuracy>

정답 값들 [100, 89, 49, 30]

MSE =
$$\frac{1}{n} \sum_{i=1}^{n} (Y_i - \hat{Y}_i)^2$$
.

$$MSE = \frac{1}{4}((100 - 100)^2 + (99 - 89)^2 + (39 - 49)^2 + (22 - 30)^2)$$

=66 이에 가까울 수록 좋다

<회귀문제 - Mean Squared Error>

Regression 모델의 종류

- Linear Regression
- Polynomial Regression
- Support Vector Regression
- Decision Tree Regression
- Random Forest Regression
- Ridge Regression
- Lasso Regression

E.O.D