#### BIG DATA ANALYTICS


WEEK-08 | Supervised Learning - Regression

Yonsei University Jungwon Seo

#### 기본원리


$$y=3x+1$$

X	у
1	4
2	7
3	10
4	?



## Regression

• Error를 최소화 할 수 있는 방정식(Equation)을 찿기



## Linear Regression

- 단순 선형회귀
  - y = wx + b
- 다중 선형회귀 (n개의 feature)
  - $y = w_1 x_1 + w_2 x_2 + \dots + w_n x_n + b$
- 가설 (Hypothesis)
  - 변수간의 관계를 유추하기 위해 수학적으로 나타낸 식
  - H(x) = wx + b

#### Loss function (손실함수)

- 실제값과 예측값과의 차이를 측정 할 수 있는 함수
- Regression Loss Functions
  - Mean Squared Error Loss
  - Mean Squared Logarithmic Error Loss
  - Mean Absolute Error Loss
- Binary Classification Loss Functions
  - Binary Cross-Entropy
  - Hinge Loss
  - Squared Hinge Loss
- Multi-Class Classification Loss Functions
  - Multi-Class Cross-Entropy Loss
  - Sparse Multiclass Cross-Entropy Loss
  - Kullback Leibler Divergence Loss

### Optimizer

- Loss function을 이용해서 error 값을 측정을한다면, 가장 최소의 error를 빠르게 찿는 알고리즘은 없을까?
- Hypotheis 재정의


$$\bullet \ h_{\theta}(x) = \theta_0 + \theta_1 x$$

Cost Function 재정의

• 
$$J(\theta_1, \theta_2) = \frac{1}{m} \sum_{i=1}^{m} (h_{\theta}(x^i) - y^i)^2$$


•  $J(\theta_1, \theta_2)$  의 최솟값 찾기


# $J(\theta_1,\theta_2)$



#### Gradient Descent

- 경사하강법
- 함수를 미분해서, 기울기가 음수인 곳을 계속 찾아간다면 언젠간 그 함수의 최솟값에 도달 하지 않을까?





### GD Step by Step

• Cost function 정의

$$J(\theta_1, \theta_2) = \frac{1}{m} \sum_{i=1}^{m} (h_{\theta}(x^i) - y^i)^2$$


- 임의의 점에서 시작
  - 예: (0,0),(10,3) 등
- J를 줄이는  $\theta_1, \theta_2$ 로 업데이트

$$\theta_j := \theta_j - \alpha \frac{\partial}{\partial \theta_j} J(\theta_0, \theta_1)$$
 (for  $j = 0$  and  $j = 1$ )

 $\alpha$ : learning rate

• 수렴 할 때까지 반복!

### Learning Rate



 $\alpha$ 는 작으면 작을 수록 좋을까?

E.O.D